

สมการ Linear Regression

จากพื้นฐานถึง Generalized Model

คู่มือสมการคณิตศาสตร์แบบครบถ้วน

เอกสารอ้างอิงสำหรับนักศึกษาและนักวิจัย

27 มิถุนายน พ.ศ. 2568

เมธานนท์ แก้วกระจ่าง

Contents

1	สมการพื้นฐาน (Basic Linear Regression)	4
1.1	Simple Linear Regression (Feature เดียว)	4
1.2	กรณีจุดข้อมูลไม่ก็จุด	4
2	สมการสำหรับ Dataset ขนาดใหญ่	4
2.1	Simple Linear Regression (Feature เดียว)	4
2.2	รูปแบบเมทริกซ์ (Simple Linear Regression)	5
3	Multiple Linear Regression	5
3.1	สมการทั่วไป	5
3.2	รูปแบบเมทริกซ์ (Multiple Linear Regression)	5
3.3	Normal Equations สำหรับ Multiple Regression	6
4	Generalized Linear Model (GLM)	6
4.1	รูปแบบทั่วไป	6
4.2	องค์ประกอบของ GLM	7
4.3	ตัวอย่าง GLM สำหรับกรณีต่างๆ	7
4.4	การประมาณค่าพารามิเตอร์ใน GLM	7
5	Regularized Regression	8
5.1	Ridge Regression (L2 Regularization)	8
5.2	LASSO Regression (L1 Regularization)	8
5.3	Elastic Net Regression	8
6	Polynomial Regression	9
6.1	สมการพื้นฐาน	9
6.2	Multivariate Polynomial Regression	9
7	Logistic Regression	9
7.1	Binary Logistic Regression	9
7.2	Maximum Likelihood Estimation	10
7.3	Multinomial Logistic Regression	10
8	Robust Regression	10
8.1	Huber Regression	10
8.2	Quantile Regression	10

9 สรุปและเปรียบเทียบ	10
9.1 ตารางสรุปสมการหลัก	11
9.2 ตารางเปรียบเทียบ Regularization	11
9.3 การวัดประสิทธิภาพ	12
10 Cross-Validation และ Model Selection	12
10.1 K-Fold Cross-Validation	12
10.2 Information Criteria	12
10.3 Regularization Path	13
11 ข้อสมมติและข้อจำกัด	13
11.1 ข้อสมมติสำคัญ	13
11.2 การตรวจสอบข้อสมมติ	13
12 บทสรุป	14

เมธานนท์ แก้วกระจ่าง

1 สมการพื้นฐาน (Basic Linear Regression)

1.1 Simple Linear Regression (Feature เดียว)

สมการทั่วไป:

$$y = \beta_0 + \beta_1 x + \varepsilon \quad (1)$$

โดยที่:

- y = ตัวแปรตาม (dependent variable)
- x = ตัวแปรอิสระ (independent variable)
- β_0 = intercept (จุดตัดแกน y)
- β_1 = slope (ความชัน)
- ε = error term (ค่าผิดพลาด)

สมการสำหรับการทำนาย:

$$\hat{y} = \beta_0 + \beta_1 x \quad (2)$$

1.2 กรณีจุดข้อมูลไม่กี่จุด

สำหรับ 2 จุด: $(x_1, y_1), (x_2, y_2)$

$$\beta_1 = \frac{y_2 - y_1}{x_2 - x_1} \quad (3)$$

$$\beta_0 = y_1 - \beta_1 x_1 \quad (4)$$

สำหรับ 3 จุด: $(x_1, y_1), (x_2, y_2), (x_3, y_3)$

ใช้ Least Squares Method:

$$\beta_1 = \frac{\sum_{i=1}^3 (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^3 (x_i - \bar{x})^2} \quad (5)$$

$$\beta_0 = \bar{y} - \beta_1 \bar{x} \quad (6)$$

2 สมการสำหรับ Dataset ขนาดใหญ่

2.1 Simple Linear Regression (Feature เดียว)

รูปแบบทั่วไป:

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad i = 1, 2, \dots, n \quad (7)$$

สมการ Normal Equations:

$$\beta_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{n \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i \sum_{i=1}^n y_i}{n \sum_{i=1}^n x_i^2 - (\sum_{i=1}^n x_i)^2} \quad (8)$$

$$\beta_0 = \bar{y} - \beta_1 \bar{x} = \frac{1}{n} \sum_{i=1}^n y_i - \beta_1 \frac{1}{n} \sum_{i=1}^n x_i \quad (9)$$

2.2 รูปแบบเมทริกซ์ (Simple Linear Regression)

สมการเมทริกซ์:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon} \quad (10)$$

โดยที่:

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}, \quad \mathbf{X} = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix}, \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix}, \quad \boldsymbol{\varepsilon} = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix} \quad (11)$$

สมการหาค่าพารามิเตอร์:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y} \quad (12)$$

3 Multiple Linear Regression

3.1 สมการทั่วไป

รูปแบบพื้นฐาน:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p + \varepsilon \quad (13)$$

สำหรับ n จุดข้อมูล:

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip} + \varepsilon_i, \quad i = 1, 2, \dots, n \quad (14)$$

3.2 รูปแบบเมทริกซ์ (Multiple Linear Regression)

สมการเมทริกซ์:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon} \quad (15)$$

โดยที่:

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}, \quad \mathbf{X} = \begin{bmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1p} \\ 1 & x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix} \quad (16)$$

$$\boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \vdots \\ \beta_p \end{bmatrix}, \quad \boldsymbol{\varepsilon} = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix} \quad (17)$$

สมการหาค่าพารามิเตอร์:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y} \quad (18)$$

3.3 Normal Equations สำหรับ Multiple Regression

สมการระบบ:

$$\mathbf{X}^T \mathbf{X} \boldsymbol{\beta} = \mathbf{X}^T \mathbf{y} \quad (19)$$

รูปแบบกระจาย:

$$\sum_{i=1}^n y_i = n\beta_0 + \beta_1 \sum_{i=1}^n x_{i1} + \beta_2 \sum_{i=1}^n x_{i2} + \cdots + \beta_p \sum_{i=1}^n x_{ip} \quad (20)$$

$$\sum_{i=1}^n x_{i1} y_i = \beta_0 \sum_{i=1}^n x_{i1} + \beta_1 \sum_{i=1}^n x_{i1}^2 + \beta_2 \sum_{i=1}^n x_{i1} x_{i2} + \cdots + \beta_p \sum_{i=1}^n x_{i1} x_{ip} \quad (21)$$

$$\vdots \quad (22)$$

$$\sum_{i=1}^n x_{ip} y_i = \beta_0 \sum_{i=1}^n x_{ip} + \beta_1 \sum_{i=1}^n x_{ip} x_{i1} + \beta_2 \sum_{i=1}^n x_{ip} x_{i2} + \cdots + \beta_p \sum_{i=1}^n x_{ip}^2 \quad (23)$$

4 Generalized Linear Model (GLM)

4.1 รูปแบบทั่วไป

สมการพื้นฐาน:

$$g(\mu_i) = \mathbf{x}_i^T \boldsymbol{\beta} \quad (24)$$

โดยที่:

- $g(\cdot)$ = link function
- $\mu_i = E[y_i]$ = expected value
- \mathbf{x}_i = vector ของ covariates สำหรับ observation ที่ i

4.2 องค์ประกอบของ GLM

1. Random Component:

$$y_i \sim f(y_i | \theta_i, \phi) \quad (25)$$

2. Systematic Component:

$$\eta_i = \mathbf{x}_i^T \boldsymbol{\beta} \quad (26)$$

3. Link Function:

$$g(\mu_i) = \eta_i \quad (27)$$

4.3 ตัวอย่าง GLM สำหรับกรณีต่างๆ

Linear Regression:

- Distribution: Normal
- Link function: Identity, $g(\mu) = \mu$
- $\mu_i = \mathbf{x}_i^T \boldsymbol{\beta}$

Logistic Regression:

- Distribution: Binomial
- Link function: Logit, $g(\mu) = \log\left(\frac{\mu}{1-\mu}\right)$
- $\log\left(\frac{\mu_i}{1-\mu_i}\right) = \mathbf{x}_i^T \boldsymbol{\beta}$

Poisson Regression:

- Distribution: Poisson
- Link function: Log, $g(\mu) = \log(\mu)$
- $\log(\mu_i) = \mathbf{x}_i^T \boldsymbol{\beta}$

4.4 การประมาณค่าพารามิเตอร์ใน GLM

Maximum Likelihood Estimation:

$$\hat{\boldsymbol{\beta}} = \arg \max_{\boldsymbol{\beta}} \log L(\boldsymbol{\beta}) \quad (28)$$

Iteratively Reweighted Least Squares (IRLS):

$$\boldsymbol{\beta}^{(t+1)} = \left(\mathbf{X}^T \mathbf{W}^{(t)} \mathbf{X} \right)^{-1} \mathbf{X}^T \mathbf{W}^{(t)} \mathbf{z}^{(t)} \quad (29)$$

โดยที่:

- $\mathbf{W}^{(t)}$ = diagonal weight matrix
- $\mathbf{z}^{(t)}$ = working response vector

5 Regularized Regression

5.1 Ridge Regression (L2 Regularization)

Cost Function:

$$J(\beta) = \frac{1}{2n} \|\mathbf{y} - \mathbf{X}\beta\|_2^2 + \alpha \|\beta\|_2^2 \quad (30)$$

รูปแบบกระจาย:

$$J(\beta) = \frac{1}{2n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \alpha \sum_{j=1}^p \beta_j^2 \quad (31)$$

สมการหาค่าพารามิเตอร์:

$$\hat{\beta}_{\text{ridge}} = (\mathbf{X}^T \mathbf{X} + \alpha \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y} \quad (32)$$

โดยที่ $\alpha \geq 0$ คือ regularization parameter และ \mathbf{I} คือ identity matrix

5.2 LASSO Regression (L1 Regularization)

Cost Function:

$$J(\beta) = \frac{1}{2n} \|\mathbf{y} - \mathbf{X}\beta\|_2^2 + \alpha \|\beta\|_1 \quad (33)$$

รูปแบบกระจาย:

$$J(\beta) = \frac{1}{2n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \alpha \sum_{j=1}^p |\beta_j| \quad (34)$$

Optimization Problem:

$$\hat{\beta}_{\text{lasso}} = \arg \min_{\beta} \left\{ \frac{1}{2n} \|\mathbf{y} - \mathbf{X}\beta\|_2^2 + \alpha \|\beta\|_1 \right\} \quad (35)$$

5.3 Elastic Net Regression

Cost Function:

$$J(\beta) = \frac{1}{2n} \|\mathbf{y} - \mathbf{X}\beta\|_2^2 + \alpha \left(\rho \|\beta\|_1 + \frac{1-\rho}{2} \|\beta\|_2^2 \right) \quad (36)$$

โดยที่:

- $\alpha \geq 0$ = regularization strength
- $0 \leq \rho \leq 1$ = mixing parameter
- เมื่อ $\rho = 1$ จะเป็น LASSO
- เมื่อ $\rho = 0$ จะเป็น Ridge

6 Polynomial Regression

6.1 สมการพื้นฐาน

Polynomial ระดับ d:

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \cdots + \beta_d x^d + \varepsilon \quad (37)$$

รูปแบบเมทริกซ์:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \varepsilon \quad (38)$$

โดยที่:

$$\mathbf{X} = \begin{bmatrix} 1 & x_1 & x_1^2 & \cdots & x_1^d \\ 1 & x_2 & x_2^2 & \cdots & x_2^d \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & x_n^2 & \cdots & x_n^d \end{bmatrix}, \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \vdots \\ \beta_d \end{bmatrix} \quad (39)$$

6.2 Multivariate Polynomial Regression

สำหรับ 2 ตัวแปร (degree 2):

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1^2 + \beta_4 x_2^2 + \beta_5 x_1 x_2 + \varepsilon \quad (40)$$

รูปแบบทั่วไป:

$$y = \sum_{i=0}^d \sum_{j=0}^{d-i} \beta_{ij} x_1^i x_2^j + \varepsilon \quad (41)$$

7 Logistic Regression

7.1 Binary Logistic Regression

Logit Function:

$$\log\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p \quad (42)$$

Probability Function:

$$p(y = 1|\mathbf{x}) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p)}} = \frac{1}{1 + e^{-\mathbf{x}^T \boldsymbol{\beta}}} \quad (43)$$

Sigmoid Function:

$$\sigma(z) = \frac{1}{1 + e^{-z}}, \quad \text{โดยที่ } z = \mathbf{x}^T \boldsymbol{\beta} \quad (44)$$

7.2 Maximum Likelihood Estimation

Log-Likelihood:

$$\ell(\beta) = \sum_{i=1}^n [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)] \quad (45)$$

Cost Function (Cross-Entropy):

$$J(\beta) = -\frac{1}{n} \sum_{i=1}^n [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)] \quad (46)$$

7.3 Multinomial Logistic Regression

สำหรับ K classes:

$$p(y = k | \mathbf{x}) = \frac{e^{\mathbf{x}^T \beta_k}}{\sum_{j=1}^K e^{\mathbf{x}^T \beta_j}}, \quad k = 1, 2, \dots, K \quad (47)$$

Softmax Function:

$$\text{softmax}(z_k) = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}} \quad (48)$$

8 Robust Regression

8.1 Huber Regression

Huber Loss Function:

$$L_\delta(r) = \begin{cases} \frac{1}{2}r^2 & \text{if } |r| \leq \delta \\ \delta|r| - \frac{1}{2}\delta^2 & \text{if } |r| > \delta \end{cases} \quad (49)$$

โดยที่ $r = y - \mathbf{x}^T \beta$ และ δ คือ threshold parameter

8.2 Quantile Regression

สำหรับ quantile ที่ τ ($0 < \tau < 1$):

$$\hat{\beta}_\tau = \arg \min_{\beta} \sum_{i=1}^n \rho_\tau(y_i - \mathbf{x}_i^T \beta) \quad (50)$$

โดยที่:

$$\rho_\tau(u) = u(\tau - \mathbf{1}_{u < 0}) = \begin{cases} \tau u & \text{if } u \geq 0 \\ (\tau - 1)u & \text{if } u < 0 \end{cases} \quad (51)$$

9 สรุปและเปรียบเทียบ

9.1 ตารางสรุปสมการหลัก

รูปแบบ	สมการพื้นฐาน	Cost Function	การหาพารามิเตอร์
Linear	$y = \beta_0 + \beta_1 x + \varepsilon$	$\frac{1}{2n} \ \mathbf{y} - \mathbf{X}\beta\ _2^2$	$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$
Ridge	$y = \mathbf{x}^T \beta + \varepsilon$	$\frac{1}{2n} \ \mathbf{y} - \mathbf{X}\beta\ _2^2 + \alpha \ \beta\ _2^2$	$\hat{\beta} = (\mathbf{X}^T \mathbf{X} + \alpha \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y}$
LASSO	$y = \mathbf{x}^T \beta + \varepsilon$	$\frac{1}{2n} \ \mathbf{y} - \mathbf{X}\beta\ _2^2 + \alpha \ \beta\ _1$	Coordinate Descent
Logistic	$\log \frac{p}{1-p} = \mathbf{x}^T \beta$	$-\frac{1}{n} \sum [y \log p + (1 - y) \log(1 - p)]$	Newton-Raphson
Polynomial	$y = \sum_{i=0}^d \beta_i x^i + \varepsilon$	$\frac{1}{2n} \ \mathbf{y} - \mathbf{X}\beta\ _2^2$	$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$

Table 1: สรุปสมการ Regression ทุกประเภท

9.2 ตารางเปรียบเทียบ Regularization

Method	Penalty	คุณสมบัติหลัก	ข้อดี/ข้อเสีย
Ridge	L2: $\ \beta\ _2^2$	Shrink coefficients	ดี: Stable, เสีย: ไม่ feature selection
LASSO	L1: $\ \beta\ _1$	Sparse solutions	ดี: Feature selection, เสีย: Unstable
Elastic Net	L1 + L2	ทั้งสองอย่าง	ดี: Balanced, เสีย: Extra parameter

Table 2: เปรียบเทียบ Regularization Methods

9.3 การวัดประสิทธิภาพ

สำหรับ Regression:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (52)$$

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (53)$$

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (54)$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (55)$$

สำหรับ Classification:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (56)$$

$$Precision = \frac{TP}{TP + FP} \quad (57)$$

$$Recall = \frac{TP}{TP + FN} \quad (58)$$

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} \quad (59)$$

10 Cross-Validation และ Model Selection

10.1 K-Fold Cross-Validation

CV Error:

$$CV_{(k)} = \frac{1}{k} \sum_{i=1}^k MSE_i \quad (60)$$

โดยที่ MSE_i คือ Mean Squared Error ของ fold ที่ i

10.2 Information Criteria

Akaike Information Criterion (AIC):

$$AIC = 2k - 2 \ln(\hat{L}) \quad (61)$$

Bayesian Information Criterion (BIC):

$$BIC = k \ln(n) - 2 \ln(\hat{L}) \quad (62)$$

โดยที่:

- k = จำนวนพารามิเตอร์
- n = จำนวนข้อมูล
- \hat{L} = maximum likelihood

10.3 Regularization Path

สำหรับ LASSO และ Ridge:

$$\alpha_{\text{optimal}} = \arg \min_{\alpha} CV(\alpha) \quad (63)$$

Grid Search:

$$\alpha \in \{10^{-4}, 10^{-3}, \dots, 10^2\} \quad (64)$$

11 ข้อสมมติและข้อจำกัด

11.1 ข้อสมมติสำคัญ

1. **Linearity:** ความสัมพันธ์เชิงเส้นระหว่าง predictors และ response
2. **Independence:** ความเป็นอิสระของ observations
3. **Homoscedasticity:** ความคงที่ของ variance
4. **Normality:** การแจกแจงปกติของ residuals (สำหรับ Linear Regression)
5. **No Multicollinearity:** ตัวแปรอิสระไม่มีความสัมพันธ์กันสูง

11.2 การตรวจสอบข้อสมมติ

Residual Analysis:

$$e_i = y_i - \hat{y}_i \quad (65)$$

$$\text{Standardized Residual} = \frac{e_i}{\sqrt{\text{MSE}(1 - h_{ii})}} \quad (66)$$

โดยที่ h_{ii} คือ leverage values

Durbin-Watson Test สำหรับ Autocorrelation:

$$DW = \frac{\sum_{i=2}^n (e_i - e_{i-1})^2}{\sum_{i=1}^n e_i^2} \quad (67)$$

12 บทสรุป

เอกสารนี้ได้นำเสนอสมการ Linear Regression ตั้งแต่ระดับพื้นฐานจนถึงขั้นสูง ครอบคลุม:

- **Linear Regression:** Simple และ Multiple
- **Regularized Methods:** Ridge, LASSO, Elastic Net
- **Generalized Linear Models:** GLM framework
- **Polynomial Regression:** สำหรับ non-linear relationships
- **Logistic Regression:** สำหรับ classification
- **Robust Methods:** Huber และ Quantile regression
- **Model Selection:** Cross-validation และ Information criteria

สมการเหล่านี้เป็นพื้นฐานสำคัญในการวิเคราะห์ข้อมูลและการเรียนรู้ของเครื่อง (Machine Learning) ที่นักศึกษาและนักวิจัยควรเข้าใจอย่างถ่องแท้

จบเอกสาร